

1 | Línea de Comandos

La línea de comandos es una interfaz de texto que permite interactuar con el sistema operativo mediante comandos. Su uso es fundamental al realizar análisis bioinformáticos, ya que la mayoría de las herramientas no cuentan con una interfaz gráfica, además de ofrecer ventajas a la hora de automatizar y ejecutar tareas en entornos HPC o en la nube.

Un comando es una instrucción que se escribe en la terminal y que se ejecuta al presionar la tecla Enter. Cada comando tiene una estructura específica, comunmente similar a la siguiente:

```
comando [subcomando] [opciones] <argumentos> sh
```

Los <argumentos> generalmente corresponde a los archivos de entrada y salida del comando y son obligatorios. Por otro lado, las opciones se utilizan para modificar el comportamiento del comando y suelen ser opcionales. Normalmente se usa el formato `--opcion` (forma larga) o `-o` (forma corta) y pueden tener un argumento asociado a la opción. Dependiendo de la herramienta, pueden existir [subcomandos].

2 | Basecalling

Basecalling es el proceso por el cual se convierte la señal eléctrica captada por los dispositivos de Oxford Nanopore en secuencias de nucleótidos. Esta conversión requiere de algoritmos computacionales avanzados, como las redes neuronales LSTM y los transformers utilizados por las opciones de basecalling actuales. Este proceso es crucial porque define la calidad de los datos, lo que afectará directamente los análisis posteriores.

Oxford Nanopore ha desarrollado múltiples basecallers a medida que ha habido avances tecnológicos. El basecaller actual es **Dorado**, el cual se puede utilizar mediante línea de comandos. Adicionalmente, está integrado en MinKNOW.

2.1 | Precisión del basecalling

Dorado cuenta con múltiples modelos de basecalling, cada uno con diferentes equilibrios entre precisión y requerimientos computacionales. Actualmente, los modelos disponibles son tres:

Modelo	Precisión Simplex	Requerimientos computacionales
fast (fast)	95.5%	
high accuracy (hac)	99.25%	7.5 veces lo requerido por fast
super accuracy (sup)	99.75%	8.5 veces lo requerido por hac




Figura 1. Precisión actual de los modelos de basecalling de Oxford Nanopore, usando el Kit V14 y celdas R10.4.1 de PromethION para secuenciación de genoma humano. Fuente: <https://nanoporetech.com/es/platform/accuracy>.

Usar el modelo sup es la opción recomendada si se busca obtener la máxima precisión posible. Sin embargo, este modelo tiene un costo computacional tan elevado que se vuelve impráctico de usar sin hardware dedicado (GPU).

2.2 | Uso básico de Dorado

 nanoporetech/dorado

Dorado posee múltiples subcomandos con distintas funcionalidades, que incluyen basecalling, demultiplexación, descarga de modelos y otras.

2.2.1 | Basecalling

Para basecalling, se utiliza el subcomando `dorado basecaller`. La forma más básica de ejecutar este comando necesita el modelo a utilizar en el basecalling y el directorio con los archivos POD5. Por ejemplo, si tenemos el directorio `pod5/` y queremos utilizar el modelo `sup`, se ejecuta el siguiente comando:

```
dorado basecaller sup pod5/ > reads.ubam
```

sh

Adicionalmente, existen múltiples opciones adicionales que se pueden visualizar en la ayuda del comando.

2.2.2 | Demultiplexación

Para demultiplexar los datos, se utiliza el subcomando `dorado demux`. Este comando requiere el archivo UBAM con los reads generado en el basecalling y el kit de barcoding. Por ejemplo, si tenemos el archivo `reads.ubam` y el kit `SQK-NBD114-24`:

```
dorado demux --output-dir basecalled_reads --kit-name SQK-NBD114-24 --emit-fastq reads.ubam
```

sh

En este ejemplo, `--output-dir` indica el directorio donde se guardarán los archivos demultiplexados, y `--emit-fastq` se utiliza para que los archivos generados estén en formato FASTQ (por defecto, se generan en BAM).

3 | Asignación taxonómica

3.1 | NanoCLUST

3.2 | EMU

3.3 | wf-16S

 epi2me-labs/wf-16s

3.3.1 | Mediante aplicación de escritorio

3.3.2 | Mediante línea de comando

Pipeline bioinformático desarrollado por EPI2ME-Labs. Cuenta con dos enfoques para la asignación taxonómica: Alineamiento de secuencias mediante Minimap2, o asignación taxonómica basada en *k*-mers mediante Kraken2. Permite utilizar tanto la base de datos de SILVA (versión 138) como la base de datos de Genbank de 16S y 18S.

En caso de utilizar Kraken2 se utiliza Bracken2 para la estimación de las abundancias.

El resultado es un archivo en formato tabular (TSV) que contiene la información de la asignación taxonómica por cada muestra, detallando la cantidad de lecturas asignadas a cada categoría taxonómica. Adicionalmente, genera un reporte en formato HTML que integra la información de asignación taxonómica, calidad de la secuenciación y métricas de diversidad por muestra.

Filtra las lecturas por tamaño (entre 800pb y 2000pb) pero por defecto no realiza filtros por calidad. Para considerar una asignación taxonómica exige un porcentaje de identidad de 95 % y una cobertura de 90%.

Por defecto el pipeline realiza la asignación taxonómica con la herramienta Minimap2 y la base de datos de 16S de Genbank. Para cambiar la herramienta de clasificación, utiliza el parámetro `--classifier`, eligiendo entre `kraken2` y `minimap2`. Para seleccionar una base de datos diferente, usa el parámetro `--database_set`, con alguna de las siguientes opciones: `ncbi_16s_18s`, `ncbi_16s_18s_28s_ITS` y `SILVA_138_1`.

3.3.3 | Ejemplo de uso

```
nextflow run epi2me-labs/wf-16s \
  --classifier kraken2 --database_set SILVA_138_1 \
  --sample_sheet samples.csv \
  --taxonomic_rank G --fastq data \
  --out_dir wf-16s_minimap_ncbi \
  -profile singularity, slurm -resume
```

sh

El pipeline requiere un archivo de muestras en formato CSV que contenga la información de las muestras y los barcodes asociados.

3.3.3.1 | Estructura del directorio

```
barcode,sample_id,alias
barcode01,1M,1M
barcode06,4H,4H
barcode08,5H,5H
barcode10,6H,6H
barcode11,6M,6M
barcode12,7H,7H
barcode13,7M,7M
```

3.3.3.2 | Estructura del archivo de muestras

Este pipeline esta pensando para ser ejecutado luego de la etapa de basecalling, por lo que se espera que los archivos FASTQ estén en la carpeta correspondiente de cada barcode. Cada carpeta de los barcodes a analizar debe encontrarse dentro de la carpeta que se indicara con el parámetro `--fastq`. La estructura del directorio debe ser la siguiente:

```
— input_directory
  |— barcode01
  |   |— reads0.fastq
  |— barcode02
  |   |— reads0.fastq
  |— barcode03
  |   |— reads0.fastq
```

3.4 | Eliminación de especies poco abundantes

3.5 | Normalización por muestra

<https://scienceparkstudygroup.github.io/microbiome-lesson/05-data-filtering-and-normalisation/index.html>

<https://carpentries-lab.github.io/metagenomics-analysis/08-Diversity-tackled-with-R/index.html>

avgdist -> no todas las muestras tienen la misma cantidad de seqs -> sampling

4 | Curvas de rarefacción

Las curvas de rarefacción permiten evaluar la riqueza de especies dentro de una comunidad en función del número de secuencias obtenidas. Nos permiten determinar si el número de secuencias obtenidas es suficiente para capturar la diversidad de la comunidad.

Para ello, se realizan muestreos aleatorios y se visualiza el número de especies observadas a medida que aumenta el número de secuencias.

Utilizaremos el paquete `iNEXT` en R para realizar las curvas de rarefacción.

```
D_abund <- iNEXT(df, datatype = 'incidence_filtered')  
plot(D_abund)
```



5 | Índices de diversidad alfa

Las métricas de diversidad alfa se utilizan para medir la diversidad dentro de una muestra o ecosistema, es decir, qué hay y cuánto hay en términos de especies.

Las métricas mas comunes de diversidad alfa son:

- Riqueza: Número de especies observadas en una muestra.
- Chao1: Estima la riqueza total (número de especies no observadas en una muestra).
- Shannon: Mide la diversidad de especies en una muestra, considerando la abundancia de las especies.

Para esto, utilizaremos el paquete `vegan` en R. Calcularemos la riqueza, equidad, índice de Shannon y Chao1.

```
data_richness <- estimateR(data_otu)  
data_evenness <- diversity(data_otu) / log(specnumber(data_otu))  
data_shannon <- diversity(data_otu, index = "shannon")
```



Podemos utilizar diferentes test estadísticos para comprobar si existen diferencias significativas entre los grupos: pruebas no paramétricas como el test de Kruskal-Wallis o el test de Mann-Whitney o pruebas paramétricas como t-test y ANOVA. Antes de utilizar pruebas paramétricas se debe comprobar la normalidad y homocedasticidad de los datos.

6 | Índices de diversidad beta

La diversidad beta nos permite representar las diferencias de diversidad entre muestras o ecosistemas, es decir, que tan similares o diferentes son las comunidades microbianas.

Estas métricas de distancia varían entre cero y uno. Las más usadas son las siguientes:

- Bray-Curtis: Mide la disimilitud entre muestras. Se basa en la abundancia de los taxones en las muestras.
- Jaccard: Mide disimilitud. Se basa en la presencia/ausencia de los taxones en las muestras, sin incluir información de la abundancia.
- Unifrac: Mide la distancia filogenética entre comunidades, considerando la presencia/ausencia, abundancias y evolución filogenética. Unweighted UniFrac considera solo la presencia o ausencia de otus (sin considerar abundancia), Weighted UniFrac considera las abundancias

Para calcular la diversidad beta necesitamos el archivo de abundancias generado en el paso anterior y un archivo de metadata.

sample	sex	Area	latitude	long	deep
1M	Male	48.2	60° 25,0	46° 41.8	60-80
4H	Female	48.2	60° 33,1	46° 02.3	120-150
5H	Female	48.2	60° 30,0	46° 36.4	30-30
6H	Female	48.2	60° 30,1	46° 42.7	30-33
6M	Male	48.2	60° 30,1	46° 42.7	30-33
7H	Female	48.1	62° 37,0	55° 26.7	30-29
7M	Male	48.1	62° 37,0	55° 26.7	30-29

CSV

Para calcular la diversidad beta utilizaremos las matrices de disimilitud de Bray-curtis y Jaccard y las proyectaremos en un espacio bidimensional mediante una PCoA.

Una PCoA ((Principal Coordinate Analysis) es una técnica de ordenación que permite reducir la dimensionalidad de los datos y visualizar la diversidad beta en un espacio de menor dimensión.

Algunas funciones utiles a utilizar son:

- `vegdist`: Permite calcular la matriz de disimilitud entre muestras. Se pueden utilizar diferentes métricas de distancia, como Bray-curtis, Jaccard, Euclidean, entre otras.
- `cmdscale`: Realiza un análisis de coordenadas principales (PCoA) a partir de una matriz de disimilitud.

```
bray_dist <- vegdist(data_otu, method = "bray")  
pcoa_res <- cmdscale(bray_dist, eig = TRUE)
```

R

HACER ANALISIS ESTADISTICOS